Instituto Tecnológico Superior Progreso
Dirección General
Subdirección académica

TECNOLÓGICO NACIONAL DE MÉXICO

INSTITUTO TECNOLÓGICO SUPERIOR PROGRESO

ASIGNATURA
Examen U2

DOCENTE
Ulises Morales Ramirez
TRABAJO
Práctica 2

Alumno:
Borges Pech Leonardo Melchor – 04220008

Progreso Yucatán, martes 18 de octubre 2026.

Boulevard Tecnológico de Progreso SN x 62, Progreso, Yucatán,
C.P. 97320 Tel. 969 934 3023 E-mail: dir01_dprogreso@tecnm.mx
www.progreso.tecnm.mx



Instituto Tecnológico Superior Progreso
Dirección General
Subdirección académica

Índice

1. Objetivo. 2
2. Librerías utilizadas y justificación. 2
3. Desarrollo por fases 2
3.1 Fase 1: Extracción de datos (Web Scraping) 2
3.2 Fase 2: Preprocesamiento de datos 3
3.3 Fase 3: Implementación del Jaccard Ponderado 4
3.4 Fase 4: Sistema de recomendación 4
4. Justificación de los pesos elegidos 5



Boulevard Tecnológico de Progreso SN x 62, Progreso, Yucatán,
C.P. 97320 Tel. 969 934 3023 E-mail: dir01_dprogreso@tecnm.mx
www.progreso.tecnm.mx



1. Objetivo.

El objetivo fue extraer la información del Top 250 de IMDb desde Letterboxd y construir un sistema de recomendación basado en el Índice de Similitud de Jaccard Ponderado, cumpliendo con lo solicitado en el examen.

2. Librerías utilizadas y justificación.

- requests: Se utilizo para realizar las peticiones HTTP GET con un User-Agent personalizado, timeout definido y verificación del código de respuesta (raise_for_status), con el fin de obtener el HTML de las páginas de forma controlada y con medidas básicas para evitar bloqueos.
- BeautifulSoup (bs4): Se empleo para analizar el HTML, localizar elementos con select/find y extraer atributos (data-item-name, data-item-link, src). Esto permitió obtener los datos sin tener que recorrer el texto con expresiones regulares.
- time: Se agrego time.sleep(1) entre las páginas del listado y time.sleep(0.5) entre las fichas individuales para no saturar el servidor y actuar de manera respetuosa al hacer múltiples peticiones.
- csv: Se uso para guardar y leer el archivo peliculas.csv, ya que permite conservar los datos de manera estructurada, portátil y reutilizable entre celdas.
- json: Se utilizo para analizar el bloque <script type="application/ld+json"> de cada ficha. Este bloque contiene metadatos estructurados en formato JSON siguiendo el estándar schema.org (Movie), lo que facilita extraer título, directores, géneros y elenco de forma precisa, sin depender de selectores HTML del diseño visual.
- unicodedata + re: Se emplearon para normalizar el texto (eliminar acentos con NFKD, pasar a minúsculas y sustituir caracteres no alfanuméricos por espacios, colapsando espacios), con el fin de homogeneizar los nombres y evitar errores al comparar.
- pandas: Se uso para crear DataFrames, transformar conjuntos (sets) a cadenas separadas por comas al exportar a CSV y para reconstruirlos al leer el archivo.

3. Desarrollo por fases

3.1 Fase 1: Extracción de datos (Web Scraping).

Acciones realizadas:





1. Se definió la URL base https://letterboxd.com/dave/list/imdb-top-250/ y se configuraron headers con User-Agent.
2. Se realizo la primera petición a la página 1, se comprobó el código HTTP 200 y se validó con raise_for_status().
3. Se detecto la paginación buscando enlaces en div.paginate-pages ul li a, obteniendo 3 páginas (pag. 1: 100, pag. 2: 100, pag. 3: 50) para completar las 250 películas.
4. Se extrajeron los elementos div.react-component[data-component-class="LazyPoster"] por página, obteniendo: titulo (data-item-name), enlace (data-item-link) e imagen (img[src]). El enlace se convirtió a URL absoluta cuando era relativo.
5. Se asigno la posición (numero_pagina - 1) * 100 + índice para mantener el orden del Top 250.
6. Se guardaron los registros en peliculas.csv con los campos posición, titulo, link e imagen.

Justificación: Detectar la paginación desde el propio HTML permitió obtener las 250 películas de forma automatizada. El uso de headers, validación HTTP y pausas (time.sleep(1)) permitió realizar la extracción de manera limpia, controlada y evadiendo bloqueos básicos.

3.2 Fase 2: Preprocesamiento de datos.

Acciones realizadas:

7. Se creo la función limpiar() para normalizar el texto: eliminar acentos, convertir a minúsculas, quitar caracteres especiales y eliminar espacios innecesarios. Esto garantiza uniformidad entre todos los registros.
8. Para cada ficha individual (250), se accedió a su URL con requests, se verifico el estado HTTP y se buscó el bloque JSON-LD.
9. ¿Por qué se usó JSON-LD? El JSON-LD (<script type="application/ld+json">) contiene los metadatos estructurados de la película según schema.org (Movie). Esto significa que los datos (titulo, directores, géneros y elenco) ya vienen organizados, evitando tener que extraerlos de múltiples selectores HTML. Esto hace la extracción más precisa, menos frágil ante cambios menores en el diseño, y más directa para transformar a conjuntos.
10. Se extrajeron los campos: name (titulo), director (lista con name), genre (lista) y actor (se tomaron los primeros 12 para considerar el elenco principal).



Boulevard Tecnológico de Progreso SN x 62, Progreso, Yucatán,
C.P. 97320 Tel. 969 934 3023 E-mail: dir01_dprogreso@tecnm.mx
www.progreso.tecnm.mx



11. Cada campo se limpió con limpiar() y se convirtió a un conjunto (set) de Python: directores, géneros y elenco. Esto permite aplicar intersección (elementos en común) y unión (total de elementos distintos), que son la base para Jaccard.
12. Se exportaron los datos enriquecidos a peliculas.csv, serializando los sets como "valor1, valor2, " ordenados para facilitar su lectura.
13. Al cargar el CSV, se reconstruyeron los sets con la función a_conjunto() para volver a tener las estructuras adecuadas para el cálculo.

Justificación: Usar JSON-LD fue la elección más adecuada porque proporciona datos semánticos ya estructurados, reduciendo la ambigüedad. Convertir Géneros, directores y Elenco a sets es fundamental para implementar correctamente el índice de Jaccard.

3.3 Fase 3: Implementación del Jaccard Ponderado.

Acciones realizadas:

14. Se definieron los pesos: w_generos = 0.5, w_directores = 0.3, w_elenco = 0.2 (suman 1.0).
15. Se implemento la función jaccard_ponderado(peli_a, peli_b) sin usar librerías que lo calculen automáticamente.
16. Para cada categoría (géneros, directores, elenco), se recorrió la unión de ambos conjuntos.
17. Por cada elemento de la unión: si el elemento está presente en ambos conjuntos, se suma su peso al numerador. En todos los casos, se suma su peso al denominador.
18. Formula resultante: J_p = (suma de w_c * [elemento en interseccion_c]) / (suma de w_c * [elemento en union_c]).

Justificación: Esta implementación respeta la lógica del Jaccard, pero ponderando por categoría. Así, una coincidencia en genero cuenta más que una coincidencia en un actor, lo cual se ajusta al objetivo de recomendar películas similares.

3.4 Fase 4: Sistema de recomendación.

Acciones realizadas:

19. Se creo la función recomendar(titulo_buscado): se normalizo el titulo con limpiar() y se buscó la película exacta en el dataset.
20. Si existe, se calculó la similitud con todas las demás películas (excluyendo la misma por posición).



21. Se ordenaron los resultados de mayor a menor similitud y se mostraron las 5 más similares con su porcentaje.

Justificación: El enfoque contenido-basado (item-item) permite recomendar películas con características comunes, mostrando resultados claros y verificables.

4. Justificación de los pesos elegidos.

- Géneros (0.5): Son los que mejor definen la temática, tono y tipo de película. Una coincidencia de genero suele ser el mayor indicador de afinidad entre películas.
- Directores (0.3): Reflejan estilo, visión y sello autoral. Tiene peso importante, pero no define por sí solo la similitud con otros títulos.
- Elenco (0.2): Los actores son relevantes, pero suelen trabajar en distintos géneros. Además, el reparto puede variar y es menos determinante para recomendar películas similares.

Por ello, se optó por priorizar temática > autoría > reparto (0.5 / 0.3 / 0.2)



Boulevard Tecnológico de Progreso SN x 62, Progreso, Yucatán,
C.P. 97320 Tel. 969 934 3023 E-mail: dir01_dprogreso@tecnm.mx
www.progreso.tecnm.mx